Données Financières

Chapitre 1

Économétrie Financière

1. Introduction

Plan du chapitre

- Section 2 : Économétrie financière
- Section 3 : Données financières
- Section 4 : Propriétés statistiques des données financières
- Section 5 : Faits stylisés

Références

- Alexander, A., *Market risk analysis*, volumes 1 et 2, Wiley, 2008.
- Brooks, C., *Introductory Econometrics for finance*, Cambridge University Press, 3ème édition, 2014.
- Campbell, J., Y., A.W. Lo et A.C. MacKinlay, *The Econometrics of financial markets*, Princeton University Press, 1997.
- Greene W. (2007), *Econometric Analysis*, sixième édition, Pearson - Prentice Hill
- Tsay, R., 2002, *Analysis of Financial Time Series*, Wiley Series

Notations

Dans ce chapitre, je vais (essayer de. . .) suivre certaines conventions de notation.

- Y : variable aléatoire
- y : réalisation
- $f_y(y)$: fonction de densité ou de masse de probabilité
- $F_y(y)$: fonction de répartition
- $Pr()$: probabilité
- $\mathbf{y}$: vecteur
- $\mathbf{Y}$: matrice

Problème : ce système ne permet pas de distinguer un vecteur (matrice) d'éléments aléatoires d'un vecteur (matrice) d'éléments non stochastiques (réalisation).

- ☒ Abadir et Magnus (2002), *Notation in econometrics: a proposal for a standard*, Econometrics Journal.

Section 2 : Économétrie Financière

Objectifs

- Définir l'économétrie financière
- Définir les notions d'échantillon et de processus générateur de données
- Distinguer modèle paramétrique et non paramétrique
- Définir les données en coupe transversale
- Définir les données de séries temporelles
- Définir les données de panel
- Résumer l'approche générale de l'économétrie financière

Qu'est-ce que l'économétrie financière ?

Pas une question simple !

- L'objectif principal de ce cours est de définir ce terme !
- L'économétrie peut être définie comme l'analyse statistique des phénomènes économiques et financiers.
  « L'économétrie est l'analyse quantitative des phénomènes économiques réels basée sur le développement conjoint de la théorie et de l'observation, reliés par des méthodes d'inférence appropriées. »
  — P. A. Samuelson, T. C. Koopmans, et J. R. N. Stone (1954)

Définition (économétrie financière)

L'économétrie financière est l'application de méthodes statistiques aux données des marchés financiers.
Elle diffère des autres formes d'économétrie car l'accent est généralement mis sur l'analyse des prix des actifs financiers négociés sur des marchés compétitifs et liquides.
Source : Wikipedia.

Objectifs de l'économétrie financière

- Combiner la théorie financière avec la théorie statistique.
- Transférer un modèle théorique (financier) en un modèle économétrique (financier).
- Modéliser les données financières.
- Prédire les variables financières ainsi que leurs relations.
- Développer des modèles spécifiques bien adaptés aux faits stylisés des données financières. **Exemple :** modèles GARCH

Est-ce utile ?

« Les personnes travaillant dans l'industrie financière ou la recherche en finance utilisent souvent des techniques économétriques dans une gamme d'activités – par exemple, pour soutenir la gestion de portefeuille et l'évaluation des titres. L'économétrie financière est essentielle pour la gestion des risques lorsqu'il est important de savoir à quelle fréquence des résultats d'investissement "mauvais" sont attendus sur les jours, semaines, mois et années à venir. »
Source : Wikipedia.

Développement académique

L'économétrie financière a attiré une attention considérable ces dernières années, tant dans le monde académique que dans la pratique financière.

- **2003 :** Prix Nobel pour Robert F. Engle pour les modèles GARCH (cf. chapitre 6).
- **2003 :** Création du *Journal of Financial Econometrics*.
- **2007 :** Création de la *Society for Financial Econometrics (SoFiE)*.

Remarque : Confusion entre termes

- **L'économétrie financière** fait le lien entre l'économie financière, les statistiques et la finance mathématique.
- **La finance empirique** couvre toutes les études financières basées sur l'analyse de données, ex. *Journal of Empirical Finance*.
- **L'économie financière** est « une discipline hautement empirique, peut-être la plus empirique parmi les branches de l'économie et même parmi les sciences sociales en général » (Campbell, Lo et MacKinlay, 1997)

Fondements de l'économétrie (financière)

L'économétrie (financière) repose fondamentalement sur quatre éléments :

1. Un **échantillon** de données
2. Un **modèle économétrique**
3. Une **méthode d'estimation**
4. Des **méthodes d'inférence**

Pourquoi utiliser un échantillon ?

Supposons que nous voulions étudier une **caractéristique / propriété** x des **individus** d'une **population**.

- Les individus (unités) de la population ne sont pas nécessairement des personnes : ce peuvent être des entreprises, des actifs, des pays, des indices temporels, etc.
- La caractéristique x peut être **quantitative** (prix, rendements, actif total, etc.) ou **qualitative** (défaut, secteur, etc.).
- La caractéristique x peut être **stochastique** ou **déterministe** (poids, taille, etc.).

Population de deux individus

Dans le cas d'une population de deux individus, l'inférence, l'économétrie, etc. (et ce cours. . .) sont inutiles.

Échantillonnage nécessaire

Lorsque la population est grande ou infinie, l'échantillonnage est le seul moyen d'étudier la caractéristique.

Définition (Population)

Une population peut être définie comme incluant toutes les personnes ou tous les éléments présentant la caractéristique que l'on souhaite comprendre.

- ☒ Dans la plupart des cas, il est impossible d'observer toute la population statistique, en raison de contraintes de coût, de temps, d'accessibilité géographique.
- ☒ Un chercheur observera plutôt un **échantillon statistique** de la population pour tenter d'apprendre quelque chose sur la population dans son ensemble.

Échantillon aléatoire

Dans la plupart des cas, l'échantillon est aléatoire :

Définition (Échantillonnage probabiliste)
Un échantillonnage probabiliste est une **méthode d'échantillonnage** dans laquelle chaque unité de la population a une chance (supérieure à zéro) d'être sélectionnée dans l'échantillon.

Conséquence : un échantillon est une collection de **variables aléatoires** même si la caractéristique x est déterministe.

Échantillon : $\{X_1, X_2, ..., X_N\}$

Exemple (échantillon aléatoire)

Considérons une population de quatre entreprises et notons $\tilde{x}$ la caractéristique (supposée non stochastique) de l'entreprise avec :

$$\tilde{x}_A = 80 \quad \tilde{x}_B = 50 \quad \tilde{x}_C = 40 \quad \tilde{x}_D = 90$$

Considérons un échantillon aléatoire de $N = 2$ entreprises noté :

$$\{X_1, X_2\}$$

avec $\{X_1\}$ caractéristique de la première entreprise sélectionnée.

On peut alors obtenir une réalisation :

$$\{x_1, x_2\} = \{50, 80\} \quad \text{ou} \quad \{x_1, x_2\} = \{90, 40\} \quad \text{ou} \quad \{x_1, x_2\} = \{90, 90\} \quad \text{etc.}$$

Échantillon aléatoire – Jeu de données

Le résultat d'un échantillonnage probabiliste est un **échantillon aléatoire**, c'est-à-dire une collection de variables aléatoires $X_1, X_2, ..., X_N$. En général, seule **une réalisation** de l'échantillon est disponible : c'est votre **jeu de données** !

$$\{X_1, X_2, ..., X_N\}$$

```
## [1] "INTC"
```

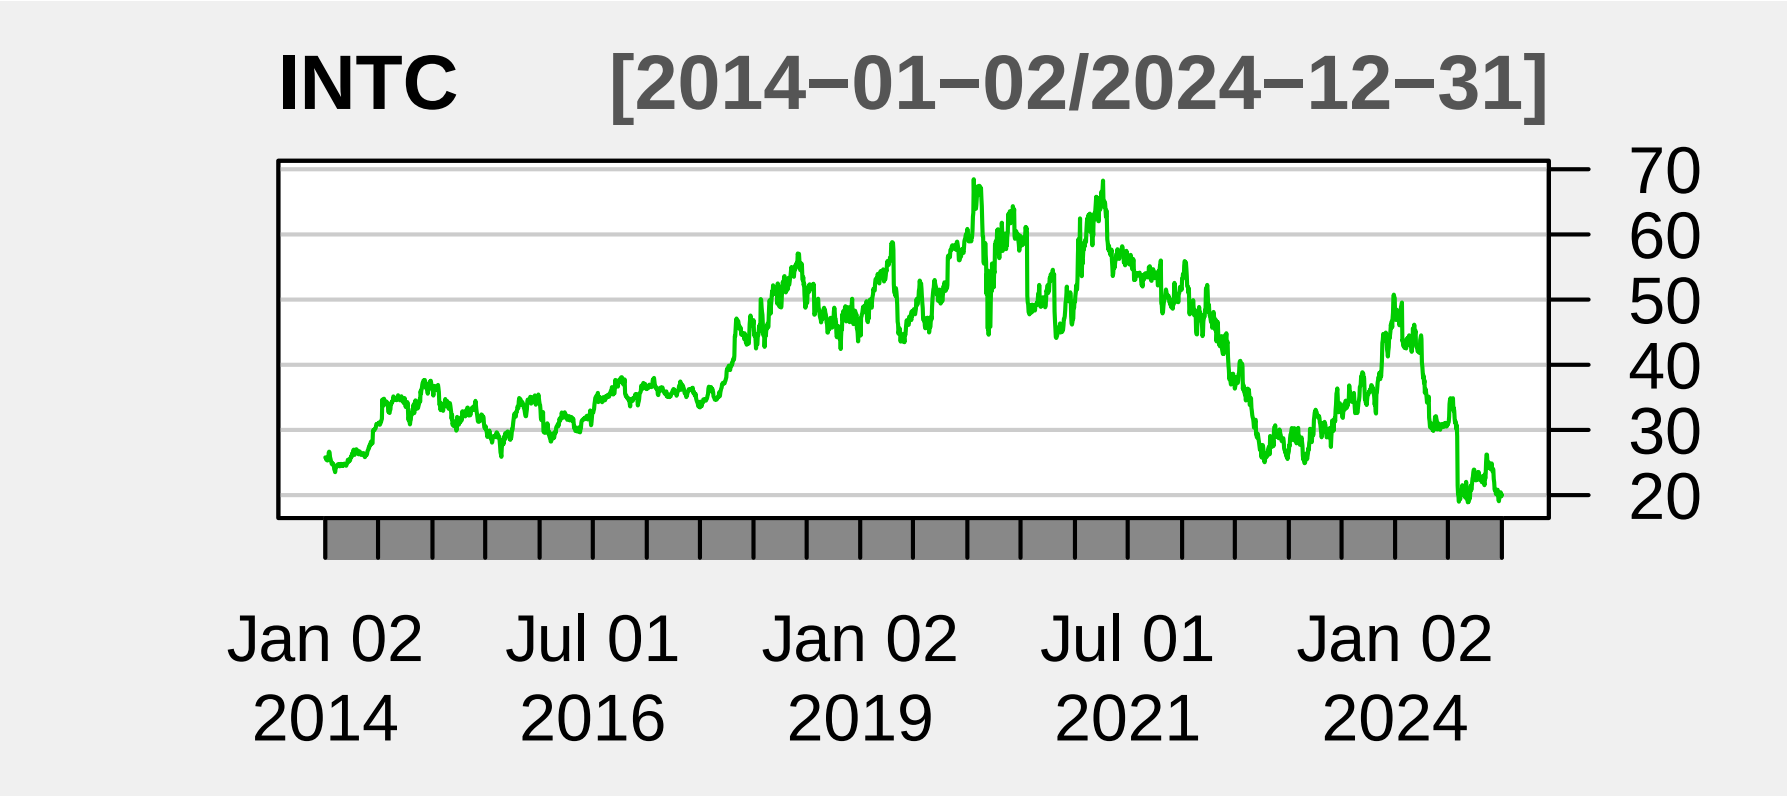

Notion de Processus Générateur de Données (DGP)

Lorsque l'on considère deux variables ou plus, la notion de population est remplacée par le concept de **Processus Générateur de Données** (DGP).

Définition (Processus Générateur de Données)
Un Processus Générateur de Données (DGP) est la distribution de probabilité conjointe qui est supposée caractériser toute la population à partir de laquelle l'échantillon a été tiré.

Exemple (DGP)
Supposons qu'il existe une relation linéaire entre les rendements R_t et $R_{m,t}$ dans la population, telle que

$$E(R_t|R_{m,t} = r_m) = \alpha + \beta r_m$$

Cette relation est le DGP pour R_t.

Le défi de l'économétrie

Le défi de l'économétrie est de tirer des conclusions sur une population (ou DGP) après avoir observé une seule réalisation $\{x_1, \ldots, x_N\}$ d'un échantillon aléatoire (votre jeu de données).

Schéma :
Population (paramètres inconnus) $\rightarrow$ Échantillon $\rightarrow$ Statistique d'échantillon (estimateur) $\rightarrow$ **INFÉRENCE**

Sources des données

En économétrie, les données proviennent de l'une des deux sources : les expériences et les observations non expérimentales.

- Les données **expérimentales** sont basées sur des expériences (randomisées contrôlées) conçues pour évaluer un traitement ou une politique ou pour étudier un effet causal.
- Les données obtenues en dehors d'un cadre expérimental sont appelées **données observationnelles**.

Toute cette leçon est consacrée aux méthodes pour traiter des données observationnelles réelles.

Types de données

Que les données soient expérimentales ou observationnelles, les jeux de données peuvent être principalement distingués en trois types :

- Données en **coupe transversale**
- Données de **séries temporelles**
- Données de **panel**

Données en coupe transversale

- Données pour différentes entités : actifs, portefeuilles, entreprises, etc.
- Pas de dimension temporelle (même si la date de collecte varie quelque peu selon les unités, elle est ignorée).
- L'ordre des données n'a pas d'importance !

Données de séries temporelles

- Données pour une seule entité (actif, entreprise, etc.) collectées sur plusieurs périodes. Observations répétées des mêmes variables (prix, volume, etc.).
- L'ordre des données est important !
- Les observations ne sont généralement pas indépendantes dans le temps.

Données de panel (longitudinales)

- Données pour plusieurs entités (actif, entreprise, etc.) dans lesquelles les résultats et caractéristiques de chaque entité sont observés à plusieurs moments.
- Combinent les problématiques de coupe transversale et de séries temporelles.
- Présentent plusieurs avantages par rapport aux données de coupe transversale et de séries temporelles (selon la question étudiée !).

Définition (Modèle économétrique)

Un modèle économétrique (financier) spécifie la relation statistique que l'on pense valable entre les différentes quantités économiques relatives à un phénomène économique particulier étudié.

- Un modèle économétrique peut être dérivé d'un modèle économique déterministe en autorisant l'incertitude, ou d'un modèle financier qui est lui-même stochastique.
- Cependant, il est aussi possible d'utiliser des modèles économétriques qui ne sont liés à aucune théorie économique financière spécifique.

Modèles paramétriques vs non paramétriques

On distingue :

- **Modèle paramétrique :** la relation (distribution de probabilité jointe) entre la variable dépendante / vecteur Y et les variables explicatives X est entièrement caractérisée par un ensemble de paramètres θ

$$Y = f(X; \theta) + \epsilon$$

où la fonction de liaison $f(.)$ est supposée connue.

- **Modèles non paramétriques et semi-paramétriques :** la fonction de liaison ne peut pas être décrite à l'aide d'un nombre fini de paramètres. La fonction de liaison est supposée inconnue et doit être estimée.

Approche générale de l'économétrie (financière)

L'approche générale de l'économétrie (financière) est la suivante :

1. **Étape 1 :** Spécification du modèle
2. **Étape 2 :** Estimation des paramètres
3. **Étape 3 :** Tests de diagnostic
   - Tests de significativité ;
   - Tests de spécification ;
   - Tests de rétrovalidation ;
   - etc.
4. **Étape 4 :** Interprétation et utilisation du modèle (prévision, étude historique, etc.)

Concepts clés (Section 2)

- ☒ Économétrie financière
- ☒ Échantillon, population et processus générateur de données
- ☒ Modèle paramétrique et non paramétrique
- ☒ Données en coupe transversale
- ☒ Données de séries temporelles
- ☒ Données de panel
- ☒ Approche générale de l'économétrie financière

Section 3 : Données Financières

Objectifs

- Introduire les différentes notions de prix d'actifs
- Définir la notion de fréquence d'échantillonnage
- Distinguer données haute fréquence (intrajournalières) vs. basse fréquence
- Définir les prix de clôture et d'ouverture
- Définir les prix ajustés (de clôture)
- Définir le rendement simple (net)
- Définir le rendement composé continûment ou log-rendement
- Calculer un rendement annualisé

Section 3 : Données Financières (suite)

Marchés liquides

La recherche quantitative en finance se concentre principalement sur les marchés financiers “liquides”, c’est-à-dire des marchés organisés où les transactions sont fréquentes et le nombre d’acteurs est important.

Exemple de marchés “liquides” : - Marché des changes - Marchés organisés de contrats à terme - Marchés d’indices boursiers - Marché des grandes capitalisations

Sur ces marchés, les prix sont enregistrés plusieurs fois par minute ou après chaque événement (données tick-by-tick).

Définition (prix)

Soit P_t le prix d'un actif au temps t.

Les prix peuvent être observés (et enregistrés) à : - Une fréquence d'échantillonnage **irrégulière** : observations tick-by-tick, observations par événement de volume (prix observés lorsque le volume dépasse un seuil donné), événements de prix (transactions associées à des changements de prix significatifs), etc. - Une fréquence d'échantillonnage **régulière** : les prix sont observés tous les m périodes de temps.

Banulescu D., Colletaz G., Hurlin C. et Tokpavi S. (2016), High Frequency Risk Measures, Journal of Forecasting, 35(3), 224-249.

Fréquences régulières

- La plupart des études en économétrie financière sont basées sur des fréquences régulières.
- En général, on distingue les fréquences intrajournalières (appelées hautes fréquences) et les fréquences plus basses car les propriétés statistiques des données correspondantes sont différentes, ainsi que les outils économétriques utilisés pour les modéliser.

Tableau : Exemples de fréquences d'échantillonnage

Haute fréquence (intra-journalière)	Basse fréquence
10 secondes	journalière
1 minute	hebdomadaire
5 minutes	mensuelle
10 minutes	trimestrielle
30 minutes	semestrielle
1 heure	annuelle
etc.	etc.

Exemple (fréquence d'échantillonnage pour les prix)

Tracer les prix (de clôture) d'Intel Corporation (Symbole : INTC) de janvier 2015 à septembre 2018, échantillonnés aux fréquences journalière, mensuelle et annuelle respectivement.

Note : Les données sont disponibles sur https://finance.yahoo.com

```
## [1] "INTC"
```

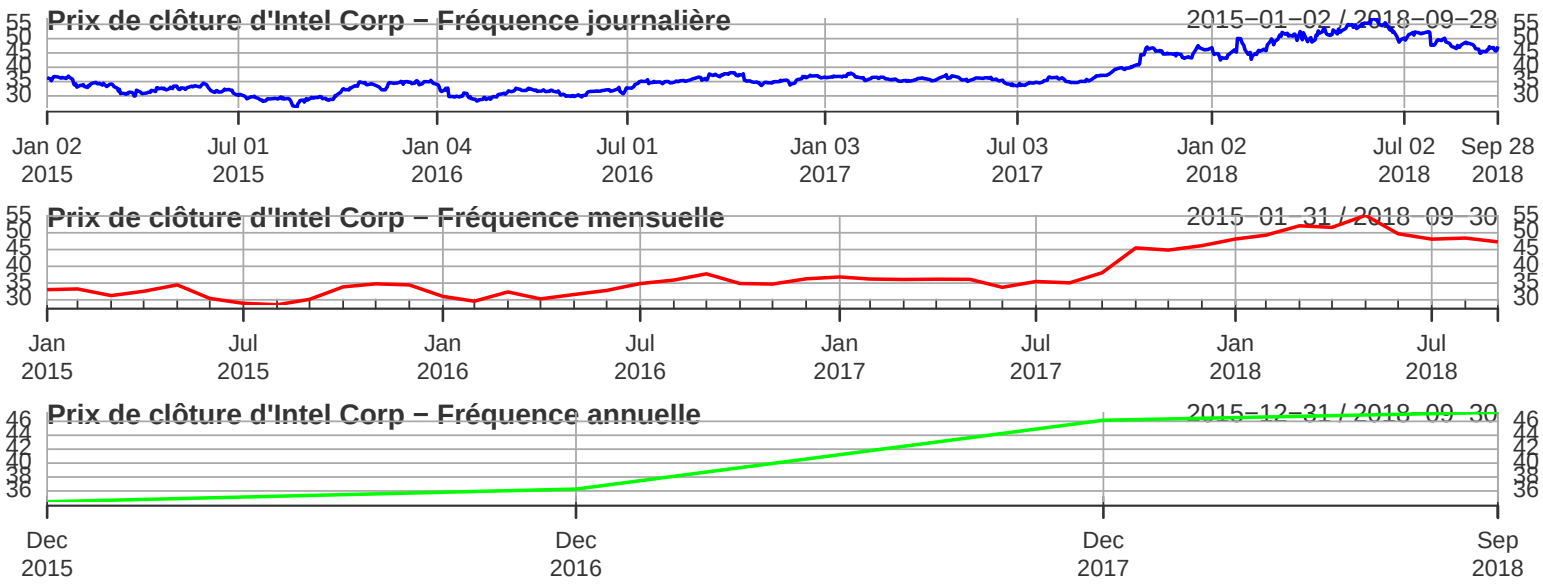

Remarque 1 : Types de prix pour une fréquence donnée

Pour une fréquence d'échantillonnage donnée (ex. : journalière), les prix peuvent être enregistrés à différents moments de la période d'observation.

Par exemple, pour une fréquence journalière, on peut considérer :

- Le **prix d'ouverture** : prix auquel un titre se négocie lors de l'ouverture d'une bourse un jour de négociation.
- Le **prix de clôture** : prix final auquel un titre est négocié un jour de négociation donné, représentant l'évaluation la plus récente d'un titre.
- Le prix le plus haut (ou le plus bas) de la journée de négociation.

En général, on considère le prix de fin de période, c'est-à-dire le prix de clôture dans le cas d'une fréquence journalière.

Remarque 2 : Prix ajustés

- Les **prix ajustés** ont été traités pour corriger les fractionnements d'actions et les dividendes.
- L'utilisation des prix ajustés nécessite de recalculer toute l'historique à chaque nouvel événement.
- Les dividendes sont mieux ajustés en les réintégrant au prix de l'action, comme s'ils étaient immédiatement utilisés pour acheter plus d'actions.

Faits : Prix vs Rendements

Bien que les **prix** soient ce que nous observons sur les marchés financiers, la plupart des études empiriques sont basées sur les **rendements**.

- Les rendements des actifs sont un résumé **sans échelle** de l'opportunité d'investissement pour les investisseurs.
- Les séries de rendements ont des **propriétés statistiques** plus attractives que les séries de prix.
- Les prix sont, en général, **non stationnaires** tandis que les rendements sont stationnaires.
- Plusieurs définitions des rendements des actifs existent.

Types de rendements

On distingue deux types de rendements :

1. Le **rendement simple (net)**
2. Le **rendement composé continûment** ou **log-rendement**

Définition (rendement proportionnel)

Détenir un actif donné pendant une période (de $t-1$ à t) donne le **rendement simple à une période** ou **rendement proportionnel** :

$$\tilde{R}_t \equiv \tilde{R}_t[1] = \frac{P_t - P_{t-1}}{P_{t-1}}$$

où P_t est le prix de l'actif (en fin de période) au temps t.

Définition (log-rendement)

Détenir un actif donné pendant une période (de $t-1$ à t) donne le rendement composé continûment ou log-rendement :

$$R_t \equiv R_t[1] = \ln\left(\frac{P_t}{P_{t-1}}\right) = p_t - p_{t-1}$$

où p_t est le log-prix de l'actif au temps t.

Remarque : Similarité entre rendements

Le rendement simple et le log-rendement sont très similaires si $\tilde{R}_t$ est proche de zéro :

$$R_t = \ln\left(\frac{P_t}{P_{t-1}}\right) = \ln\left(1 + \left(\frac{P_t}{P_{t-1}} - 1\right)\right) = \ln\left(1 + \tilde{R}_t\right) \simeq \tilde{R}_t \quad \text{si } \tilde{R}_t \simeq 0$$

Exemple (rendements simples et log-rendements)

Le prix de clôture de l'action Intel Corporation (INTC) était égal à 47,17$ le 16 août 2018 et 46,9$ le 17 août. Le rendement journalier est alors égal à :

$$\tilde{R}_{17/08} = \frac{46.9 - 47.7}{47.7} = -0.0058 = -0.58\%$$

$$R_{17/08} = \ln\left(\frac{46.9}{47.7}\right) = -0.0057 = -0.57\%$$

Exemple (Échantillon)

Considérons un échantillon de prix de clôture journaliers pour l'action Intel Corp. (symbole : INTC) du 19 août 2013 au 17 août 2018 (5 ans).

Question : comparer les rendements journaliers (simples) et les log-rendements journaliers.

Note : La taille de l'échantillon T est alors égale à 1 259. Chaque année correspond à environ 250 cotations, ce qui implique environ $250 \times 5 = 1250$ *observations pour 5 ans.*

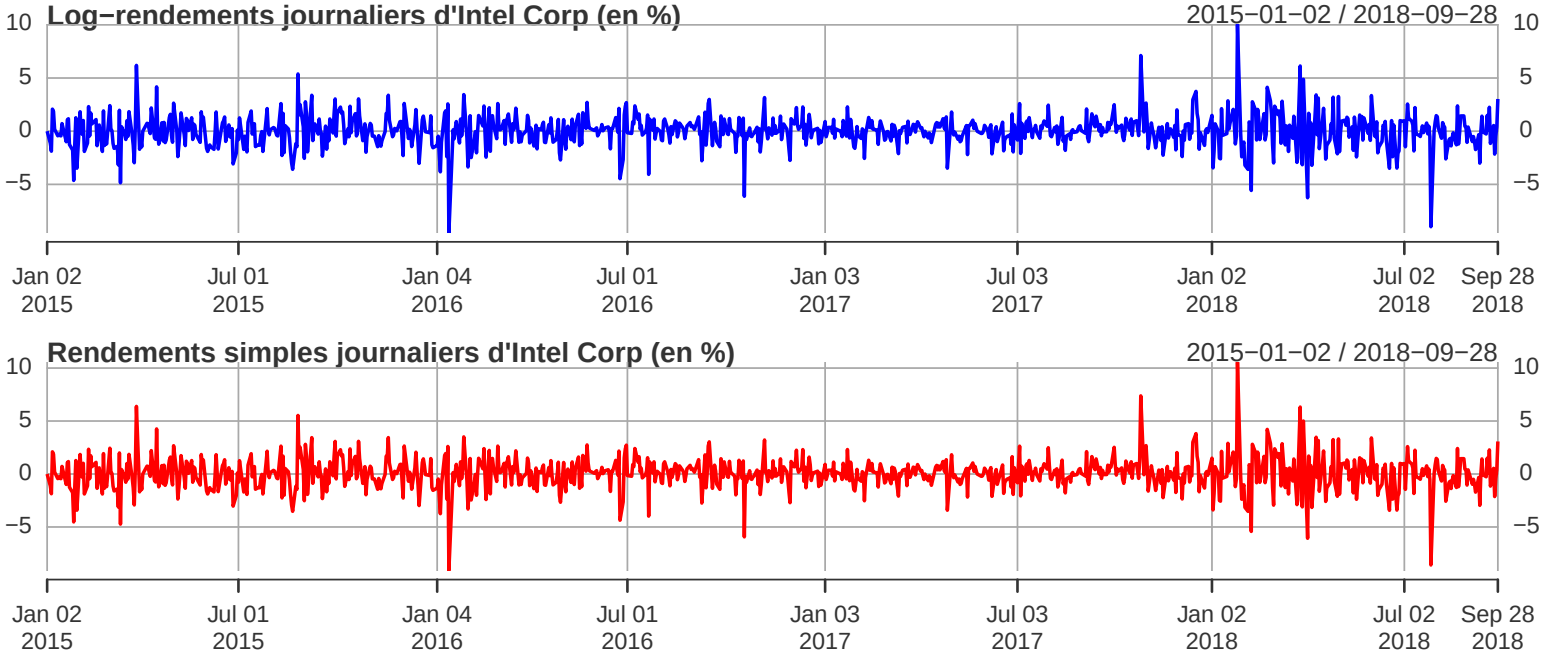

Notations (suite)

Pour le reste de ce chapitre et du cours, nous conserverons le cadre suivant :

- Nous observons le prix de l'actif en fin de période P_t au temps t.
- Nous considérons les log-rendements à une période correspondants R_t.
- La fréquence (périodicité) des observations peut être journalière, hebdomadaire, mensuelle, etc.
- Nous collectons un échantillon de T prix $\{P_1, \ldots, P_T\}$, où T est la taille de l'échantillon.

Définition (rendement à k périodes)

Le log-rendement à k périodes est donné par :

$$R_t[k] = \sum_{j=0}^{k-1} R_{t-j}[1].$$

Preuve : Les log-rendements sont assez pratiques car la multiplication devient addition !

$$R_t[k] = \ln\left(\frac{P_t}{P_{t-k}}\right) = \ln\left(\frac{P_t}{P_{t-1}} \times \frac{P_{t-1}}{P_{t-2}} \times \ldots \times \frac{P_{t-k+1}}{P_{t-k}}\right)$$

$$= \sum_{j=0}^{k-1} \ln\left(\frac{P_{t-j}}{P_{t-j-1}}\right) = \sum_{j=0}^{k-1} R_{t-j}[1]$$

Exemple (rendement à k périodes)

Considérons un actif pour lequel nous observons les rendements journaliers suivants les 17, 18 et 19 août 2018 :

$$R_{17/08} = -0.57\% \quad R_{18/08} = 0.32\% \quad R_{19/08} = 0.14\%$$

Question : quel est le log-rendement observé le 19/08 sur une période de trois jours ?

Réponse : nous savons que $R_t[k] = \sum_{j=0}^{k-1} R_{t-j}[1]$, donc nous avons :

$$R_{19/08}[3] = R_{19/08} + R_{18/08} + R_{17/08} = 0.14 + 0.32 - 0.57 = -0.11\%$$

Définition (rendement annualisé)

Si l'actif est détenu pendant k années, alors le **log-rendement annualisé (moyen)** est défini comme :

$$\text{Annualisé}\left(R_t[k]\right) = \frac{1}{k}\sum_{j=0}^{k-1} R_{t-j}[1]$$

Le rendement simple annualisé est :

$$\text{Annualisé}\left(\tilde{R}_t[k]\right) = \exp\left(\frac{1}{k}\sum_{j=0}^{k-1} R_{t-j}[1]\right) - 1 = \left(\prod_{j=0}^{k-1}\left(1+\tilde{R}_{t-j}\right)\right)^{1/k} - 1$$

Exemple (rendement annualisé)

Considérons un actif pour lequel nous observons un rendement journalier égal à :

$$R_t[1] = 0.013\%$$

Question : quel est le log-rendement annualisé correspondant ?

Réponse : Le rendement annualisé est égal à :

$$\text{Annualisé } (R_t[1]) = \frac{1}{1/365} R_t[1] = 365 \times 0.013\% = 4.745\%$$

Définition (rendement excédentaire)

Dans de nombreuses applications, il est pratique d'utiliser un **rendement excédentaire** défini comme :

$$\text{rendement excédentaire} = R_t - R_{f,t}$$

où $R_{f,t}$ est un taux de référence.

Concepts clés (Section 3)

- ☒ Prix et fréquence d'échantillonnage
- ☒ Données haute fréquence (intrajournalières) vs basse fréquence
- ☒ Prix de clôture, d'ouverture, plus haut, plus bas
- ☒ Prix ajustés
- ☒ Rendements simples vs log-rendements
- ☒ Rendements à k périodes
- ☒ Rendement annualisé
- ☒ Rendement excédentaire

Section 4 : Propriétés Statistiques des Données Financières

Objectifs

- Introduire le concept de distribution des rendements
- Définir les moments centraux et non centraux de la distribution des rendements
- Définir la moyenne, variance, asymétrie et kurtosis
- Définir les notions d'échantillon, d'estimateur et d'estimation
- Étudier la distribution d'échantillonnage d'un estimateur ou d'une statistique descriptive

Notations

Définition (distribution des rendements)

Nous représentons les log-rendements par la **variable aléatoire à valeurs réelles** R_t (ou $R_t[k]$). La distribution de R_t est appelée **distribution des rendements**.

- La **fonction de densité de probabilité (pdf)** de R_t est notée $f_R(r)$.
- La **fonction de répartition (cdf)** de R_t est notée $F_R(r)$ telle que :

$$Pr(R_t \leq r) \equiv F_R(r) = \int_{-\infty}^{r} f_R(x)\, dx$$

Exemple (hypothèse de normalité)

Supposons que le rendement R_t ait une distribution normale :

$$R_t \sim \mathcal{N}\left(\mu, \sigma^2\right)$$

avec μ l'espérance (moyenne) du rendement et σ^2 la variance du rendement. Alors, la pdf et la cdf de R_t sont respectivement définies par :

$$f_R(r) = \frac{1}{\sigma}\phi\left(\frac{r-\mu}{\sigma}\right) = \frac{1}{\sigma\sqrt{2\pi}}\exp\left(-\frac{(r-\mu)^2}{2\sigma^2}\right)$$

$$F_R(r) = \Phi\left(\frac{r-\mu}{\sigma}\right) = \int_{-\infty}^{r} f_R(x)\,dx$$

où $\phi(\cdot)$ et $\Phi(\cdot)$ désignent respectivement la pdf et la cdf de la distribution normale standard.

Moments de la distribution

La distribution des rendements peut être caractérisée soit par sa pdf, soit par ses **moments**.

Définition (moments non centraux et centraux)

Le $k^{\text{ème}}$ **moment non central** de R_t est donné par :

$$m_k = \mathrm{E}\left(R_t^k\right) = \int_{-\infty}^{\infty} x^k f_R(x)\, dx$$

Le $k^{\text{ème}}$ **moment central** de R_t est donné par :

$$\mu_k = \mathrm{E}\left((R_t - m_1)^k\right) = \int_{-\infty}^{\infty} (x - m_1)^k f_R(x)\, dx$$

avec $m_1 = \mathrm{E}(R_t)$ la moyenne de la distribution des rendements.

Les quatre premiers moments

En économétrie financière, nous nous intéressons principalement aux quatre premiers moments :

1. **Moyenne**
2. **Variance**
3. **Asymétrie**
4. **Kurtosis**

```
## [1] "AAPL"
```

Table 2: Exemple : Moments des rendements d'Apple (AAPL) 2020-2023

Moment	Valeur	Description
Moyenne	0.0009360	Tendance centrale
Variance	0.0004464	Dispersion autour de la moyenne
Asymétrie	-0.1392095	Symétrie de la distribution
Kurtosis	7.9672772	Épaisseur des queues

Définition (moyenne et variance)

La **moyenne** (espérance) du rendement R_t :

$$\mu \equiv m_1 = \mathrm{E}\left(R_t\right) = \int_{-\infty}^{\infty} x\, f_R(x)\, dx$$

La **variance** du rendement R_t :

$$\sigma^2 \equiv \mathrm{V}\left(R_t\right) = \mathrm{E}\left(\left(R_t - \mu\right)^2\right) = \int_{-\infty}^{\infty} \left(x - \mu\right)^2 f_R(x)\, dx$$

Définition (volatilité)

La **volatilité** correspond à l'écart-type de la distribution des rendements :

$$\text{Volatilité} \equiv \sigma = \sqrt{\mathbf{V}(R_t)}$$

Définition (coefficient d'asymétrie)

Le troisième moment central mesure l'asymétrie de la distribution :

$$\mu_3 = \mathrm{E}\left((R_t - \mu)^3\right) = \int_{-\infty}^{\infty} (x - \mu)^3 f_R(x)\, dx$$

Le coefficient d'asymétrie (standardisé) est défini comme :

$$S(R_t) = \mathrm{E}\left(\left(\frac{R_t - \mu}{\sigma}\right)^3\right) = \frac{\mu_3}{\sigma^3}$$

Interprétation de l'asymétrie

- Lorsque $S(R_t) < 0$, les grandes réalisations de R_t sont plus souvent négatives que positives (c'est-à-dire que les krachs sont plus probables que les booms).
- La distribution est dite **asymétrique à gauche**.
- Pour les distributions symétriques (ex. : normale, Student, etc.), le coefficient d'asymétrie est nul : $S(R_t) = 0$.

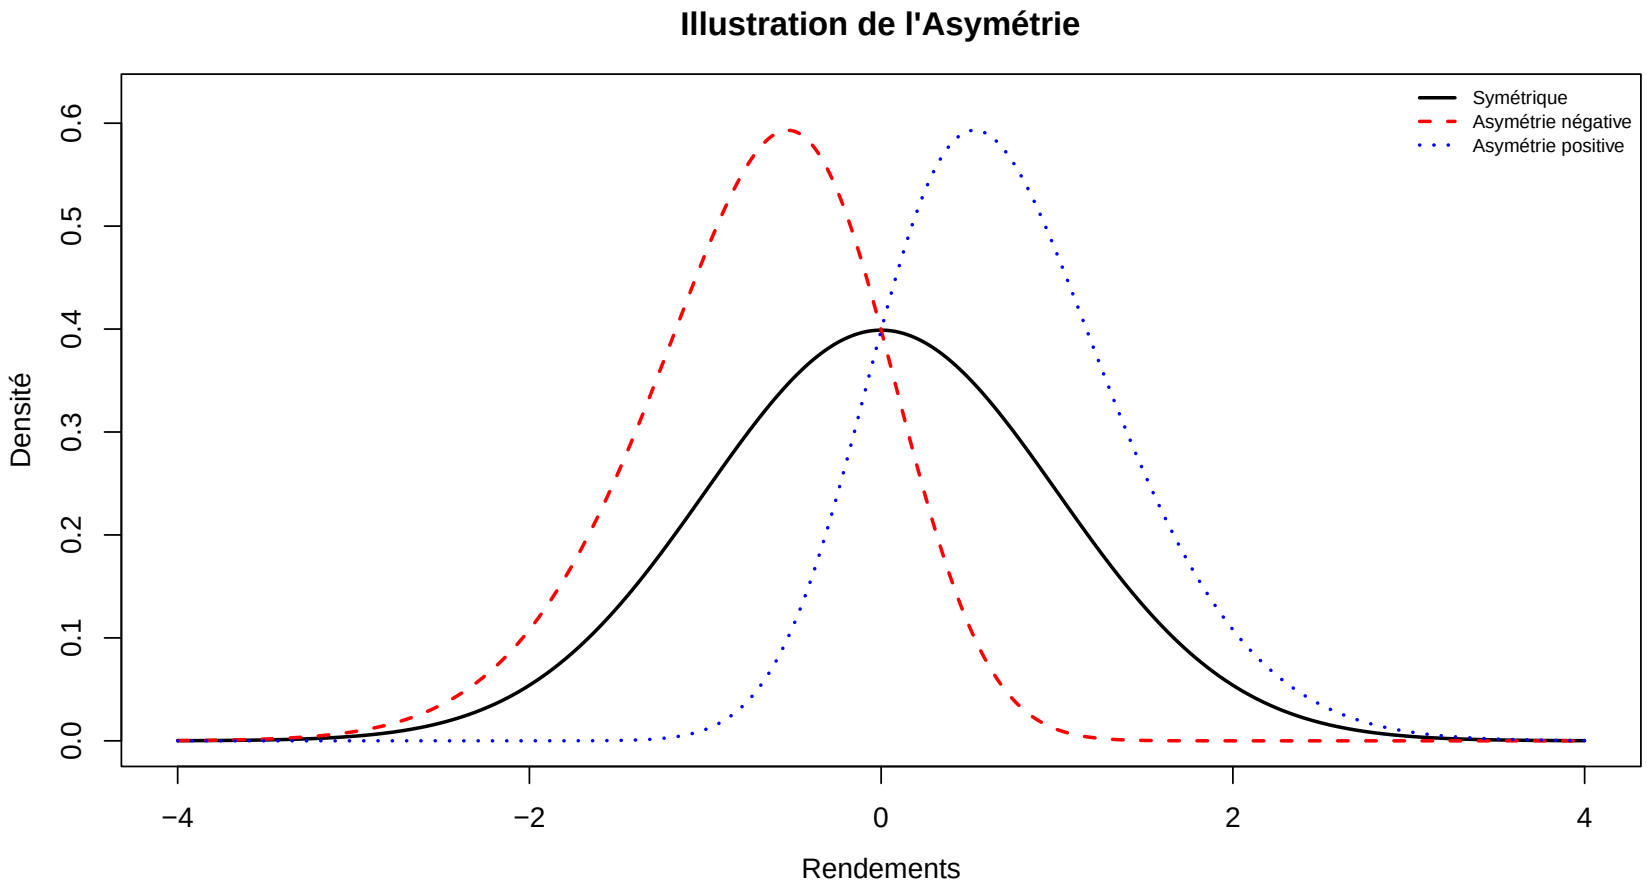

Définition (coefficient de kurtosis)

Le quatrième moment central mesure l'épaisseur des queues de la distribution :

$$\mu_4 = \mathrm{E}\left((R_t - \mu)^4\right) = \int_{-\infty}^{\infty} (x - \mu)^4 f_R(x)\, dx$$

Le coefficient de kurtosis (standardisé) est défini comme :

$$\mathrm{K}(R_t) = \mathrm{E}\left(\left(\frac{R_t - \mu}{\sigma}\right)^4\right) = \frac{\mu_4}{\sigma^4}$$

Propriétés de la kurtosis

Fait (distribution normale) : Pour une **distribution normale** $R_t \sim \mathcal{N}(\mu, \sigma^2)$, le coefficient de kurtosis est égal à 3 :

$$\mathrm{K}(R_t) = 3$$

Note : la distribution gaussienne n'est pas la seule à avoir une kurtosis égale à 3.

Classification selon la kurtosis

- Si $\mathrm{K}(R_t) > 3$: la distribution de R_t est dite **leptokurtique** (queues épaisses).
- Si $\mathrm{K}(R_t) = 3$: la distribution de R_t est dite **mésokurtique**.
- Si $\mathrm{K}(R_t) < 3$: la distribution de R_t est dite **platykurtique** (queues fines).
- Le **coefficient d'excès de kurtosis** est égal à $\mathrm{K}(R_t) - 3$.

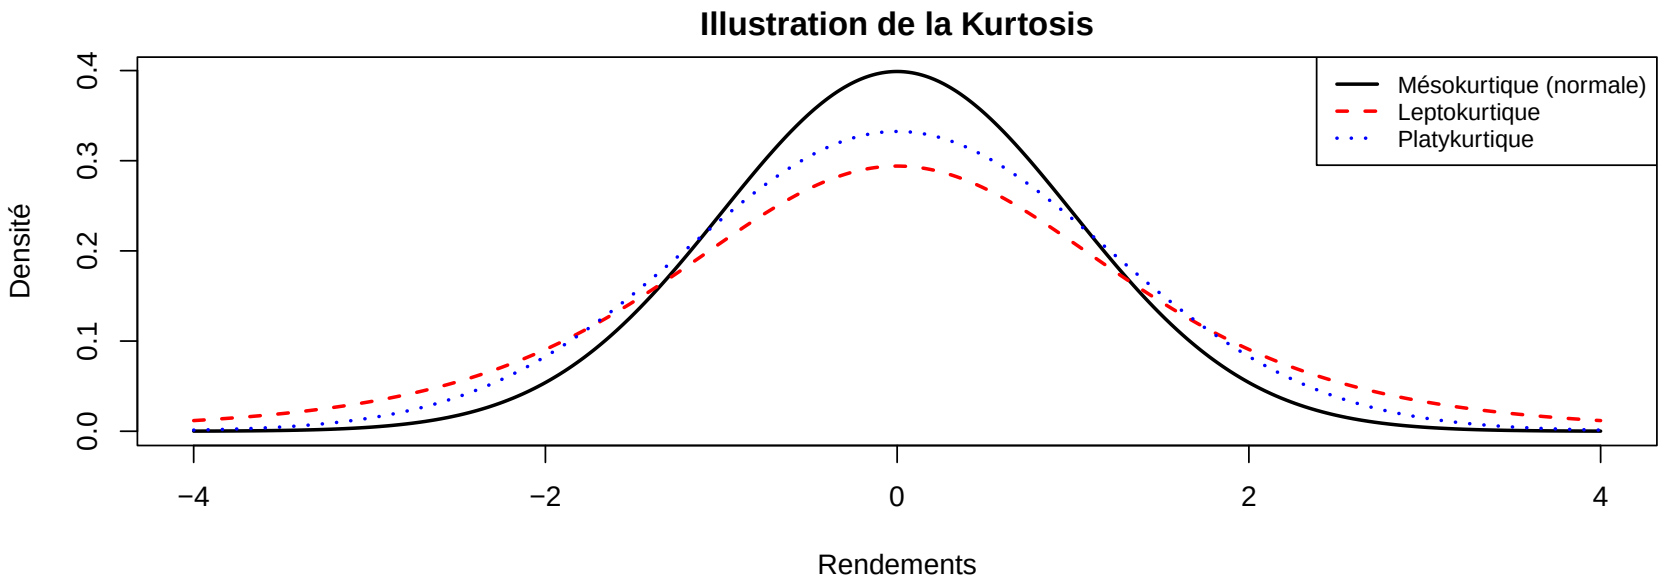

Résumé des moments

Chaque moment (central ou non central) donne une information sur la distribution des rendements :

Table 3: Résumé des quatre premiers moments

Moment	Formule	Interprétation
Moyenne	$\mathrm{E}(R_t) = \mu$	Indicateur de tendance centrale
Variance	$\mathrm{V}(R_t) = \mathrm{E}\left((R_t - \mu)^2\right) = \sigma^2$	Indicateur de dispersion autour de μ
Asymétrie	$S(R_t) = \mathrm{E}\left((R_t - \mu)^3\right)/\sigma^3$	Indicateur de symétrie
Kurtosis	$\mathrm{K}(R_t) = \mathrm{E}\left((R_t - \mu)^4\right)/\sigma^4$	Indicateur d'épaisseur des queues

Exemple (distribution normale)

Si nous supposons que les rendements sont **normalement** distribués avec $R_t \sim \mathcal{N}(\mu, \sigma^2)$, alors :

$$\begin{aligned} \mathrm{E}(R_t) &= \mu \\ \mathrm{V}(R_t) &= \sigma^2 \\ S(R_t) &= 0 \\ \mathrm{K}(R_t) &= 3 \end{aligned}$$

La distribution normale est **symétrique** et par définition **mésokurtique**.

Exemple (distribution de Student)

Si nous supposons que le rendement R_t a une **distribution de Student** avec ν degrés de liberté, i.e. $R_t \sim t(\nu)$, alors nous avons :

$$\begin{aligned}
\mathrm{E}(R_t) &= 0 \\
\mathrm{V}(R_t) &= \frac{\nu}{\nu - 2} \quad \text{si } \nu > 2 \\
S(R_t) &= 0 \\
\mathrm{K}(R_t) &= 3 + \frac{6}{\nu - 4} \quad \text{si } \nu > 4
\end{aligned}$$

La distribution de Student est **symétrique** et **leptokurtique** (si ν est "petit"). Son excès de kurtosis diminue avec le nombre de degrés de liberté. Quand ν tend vers ∞, $t(\nu) \approx \mathcal{N}(0, 1)$, et la distribution est mésokurtique.

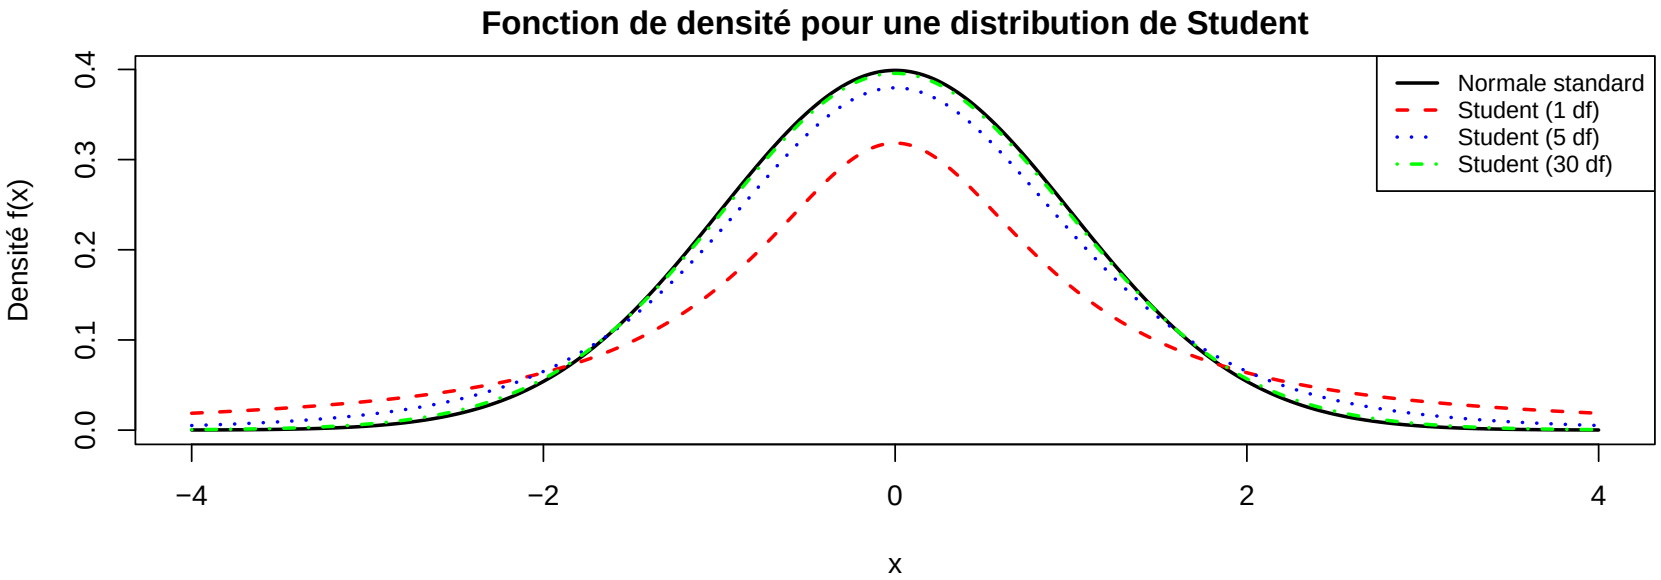

Remarques importantes

- Les moments permettent de caractériser la forme de la distribution des rendements.
- Cependant, les moments (théoriques) sont inobservables et nous devons les estimer.
- Notons $\{R_1, \ldots, R_T\}$ un échantillon de variables i.i.d. qui ont la même distribution que R_t.
- Notons $\{r_1, \ldots, r_T\}$ la réalisation de cette séquence $\rightarrow$ votre jeu de données.

Définition (estimateur)

Un estimateur est toute fonction $T(R_1, R_2, \ldots, R_T)$ d'un échantillon. Toute statistique descriptive est un estimateur ponctuel.

Exemple (moyenne d'échantillon) : Supposons que $R_1, R_2, \ldots, R_T$ soient des variables aléatoires i.i.d. La moyenne d'échantillon (ou moyenne empirique) :

$$\widehat{\mu}_T \equiv \overline{R}_T = \frac{1}{T} \sum_{t=1}^{T} R_t$$

est un estimateur de la moyenne (théorique) $\mu = \mathrm{E}(R_t)$.

Exemple (variance d'échantillon)

Supposons que $R_1, R_2, ..., R_T$ soient des variables aléatoires i.i.d. La **variance empirique** :

$$\widehat{\sigma}_T^2 = \frac{1}{T-1} \sum_{t=1}^{T} (R_t - \overline{R}_T)^2$$

est un estimateur de la variance (théorique) $\sigma^2 = \mathbf{V}(R_t)$.

Note : le dénominateur est égal à $T-1$ pour définir une variance d'échantillon corrigée du biais en petits échantillons (cf. chapitre 2).

Exemple (asymétrie d'échantillon)

Supposons que $R_1, R_2, ..., R_T$ soient des variables aléatoires i.i.d. Le coefficient d'asymétrie empirique :

$$\widehat{S}_T = \frac{1}{T}\sum_{t=1}^{T}\left(\frac{R_t - \overline{R}_T}{\widehat{\sigma}}\right)^3 = \frac{T^{-1}\sum_{t=1}^{T}\left(R_t - \overline{R}_T\right)^3}{\left((T-1)^{-1}\sum_{t=1}^{T}\left(R_t - \overline{R}_T\right)^2\right)^{3/2}}$$

est un estimateur de l'asymétrie théorique $S(R_t)$.

Exemple (kurtosis d'échantillon)

Supposons que $R_1, R_2, ..., R_T$ soient des variables aléatoires i.i.d. Le coefficient de kurtosis empirique :

$$\widehat{K}_T = \frac{1}{T}\sum_{t=1}^{T}\left(\frac{R_t - \overline{R}_T}{\widehat{\sigma}}\right)^4 = \frac{T^{-1}\sum_{t=1}^{T}\left(R_t - \overline{R}_T\right)^4}{\left((T-1)^{-1}\sum_{t=1}^{T}\left(R_t - \overline{R}_T\right)^2\right)^2}$$

est un estimateur de la kurtosis théorique $\mathrm{K}(R_t)$.

Nature aléatoire des estimateurs

Fait : Un estimateur $\widehat{\theta}$ est une variable aléatoire.

Conséquence : $\widehat{\theta}$ a une distribution de probabilité (marginale ou conditionnelle). Cette distribution d'échantillonnage est caractérisée par une pdf $f_{\widehat{\theta}}(u)$.

Définition (Distribution d'échantillonnage) :
La distribution de probabilité d'un estimateur (ou d'une statistique) est appelée **distribution d'échantillonnage**.

Conséquence : La distribution d'échantillonnage de $\widehat{\theta}$ est caractérisée par des moments tels que l'espérance $\mathrm{E}\left(\widehat{\theta}\right)$, la variance $\mathrm{V}\left(\widehat{\theta}\right)$, etc.

Définition (estimation)

Une **estimation** ponctuelle est la valeur réalisée d'un estimateur (c'est-à-dire un nombre) obtenue lorsqu'un échantillon est effectivement prélevé. Pour un estimateur $\widehat{\theta}$, elle peut être notée $\widehat{\theta}(y)$.

Exemple (estimation ponctuelle) :
Par exemple, une réalisation de l'estimateur $\overline{R}_T$, notée $\overline{r}_T$, est définie comme :

$$\overline{r}_T = \frac{1}{T}\sum_{t=1}^{T} r_t$$

- Si $T = 3$ et $\{r_1, r_2, r_3\} = \{3, -1, 2\}$ alors $\overline{r}_T = 1.333$.
- Si $T = 3$ et $\{r_1, r_2, r_3\} = \{4, -8, 1\}$ alors $\overline{r}_T = -1$.
- etc.

Statistiques descriptives

Les **statistiques descriptives** associées à un échantillon correspondent aux réalisations (estimations) de statistiques particulières (estimateurs) telles que la moyenne d'échantillon, la variance d'échantillon, le coefficient d'asymétrie d'échantillon, le coefficient de kurtosis d'échantillon, etc.

Note : la plupart des logiciels d'économétrie et de statistique calculent les principales statistiques descriptives (moyenne, variance, asymétrie, kurtosis, etc.).

Table 4: Statistiques descriptives des rendements d'Apple (AAPL) 2020-2023

Statistique	Valeur	Description
Moyenne	0.0009360	Tendance centrale
Médiane	0.0008572	Valeur médiane
Écart-type	0.0211276	Dispersion
Asymétrie	-0.1392095	Symétrie de la distribution
Kurtosis	7.9672772	Épaisseur des queues
Minimum	-0.1377081	Valeur minimale
Maximum	0.1131575	Valeur maximale

Résumé : Moments populationnels vs échantillonnaux

Table 5: Comparaison moments populationnels vs échantillonnaux

	Population (nombres réels)	Échantillon (variables aléatoires)
Moment	Population	Échantillon
Moyenne	$\mathrm{E}(R_t) = \mu$	$\widehat{\mu}_T = \frac{1}{T}\sum_{t=1}^{T} R_t$
Variance	$\mathrm{V}(R_t) = \sigma^2$	$\widehat{\sigma}_T^2 = \frac{1}{T-1}\sum_{t=1}^{T}(R_t - \overline{R}_T)^2$
Asymétrie	$S(R_t)$	$\widehat{S}_T = \frac{1}{T}\sum_{t=1}^{T}\left(\frac{R_t - \overline{R}_T}{\widehat{\sigma}}\right)^3$
Kurtosis	$K(R_t)$	$\widehat{K}_T = \frac{1}{T}\sum_{t=1}^{T}\left(\frac{R_t - \overline{R}_T}{\widehat{\sigma}}\right)^4$

Autres statistiques de dispersion

En économétrie financière, nous considérons également d'autres statistiques de **dispersion** :

Définition (Médiane des écarts absolus - MAD) :
Le **MAD** est une mesure robuste (aux valeurs aberrantes) de la variabilité :

$$\text{MAD} = \text{median}\left(|r_t - \text{median}(r_t)|\right)$$

Définition (Écart interquartile - IQR) :
L'**IQR** est une autre mesure de dispersion robuste :

$$\text{IQR} = Q(0.75) - Q(0.25)$$

où $Q(p)$ est le quantile empirique de niveau p.

Table 6: Mesures robustes de dispersion - Rendements d'AAPL

Mesure	Description	Valeur	Caractéristique
MAD (Median Absolute Deviation)	Médiane des écarts absolus à la médiane	0.011003	Robuste aux valeurs extrêmes
IQR (Interquartile Range)	Différence entre les 3ème et 1er quartiles	0.021815	Dispersion des 50% centraux

Qualités d'un estimateur

Question : Qu'est-ce qui constitue un bon estimateur ?

L'idée est d'étudier les **propriétés de la distribution d'échantillonnage** et surtout ses **moments** tels que :

- $\mathrm{E}(\widehat{\theta})$ pour le biais,
- $\mathrm{V}(\widehat{\theta})$ pour la précision,
- $S(\widehat{\theta})$ pour la symétrie,
- etc.

Propriétés des estimateurs

Les estimateurs sont comparés sur la base d'une variété d'attributs :

1. **Propriétés en échantillon fini** (ou distribution en échantillon fini) : attributs qui peuvent être comparés quelle que soit la taille de l'échantillon.
2. Cependant, la distribution en échantillon fini n'est connue que dans le cas d'hypothèses distributionnelles spécifiques sur R_t (typiquement, normalité).
3. Lorsque l'hypothèse de normalité n'est plus valable (et que la distribution en échantillon fini est inconnue), les estimateurs sont évalués sur la base de leurs **propriétés asymptotiques** (en grand échantillon).

Théorème (distributions en échantillon fini)

Si nous supposons que les rendements $R_1, R_2, ..., R_T$ sont i.i.d. et **normalement distribués** avec $R_t \sim \mathcal{N}(\mu, \sigma^2)$, alors la moyenne d'échantillon a une **distribution en échantillon fini** normale :

$$\widehat{\mu}_T \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{T}\right) \quad \forall T \in \mathbb{N}$$

La variable transformée $(T-1)\widehat{\sigma}_T^2/\sigma^2$ a une distribution exacte/échantillon fini du Chi-deux avec $T-1$ degrés de liberté :

$$\frac{(T-1)}{\sigma^2}\widehat{\sigma}_T^2 \sim \chi^2(T-1) \quad \forall T \geq 2$$

Exemple (distribution en échantillon fini)

Si nous supposons que les rendements $R_1, R_2, ..., R_T$ sont $\mathcal{N}.i.d.(\mu, \sigma^2)$, si $T = 3$, alors :

$$\widehat{\mu}_3 \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{3}\right)$$

$$2 \times \frac{\widehat{\sigma}_T^2}{\sigma^2} \sim \chi^2(2)$$

Si $T = 10$, alors :

$$\widehat{\mu}_{10} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{10}\right)$$

$$9 \times \frac{\widehat{\sigma}_T^2}{\sigma^2} \sim \chi^2(9)$$

Question : Que faire quand la distribution est inconnue ?

Dans la plupart des cas, il est impossible de dériver la distribution exacte/échantillon fini pour l'estimateur (ou une variable transformée).

Deux raisons :

1. Dans certains cas, la distribution exacte de $R_1, R_2, \ldots, R_T$ est connue, mais la fonction $T(\cdot)$ est trop compliquée pour dériver la distribution de $\widehat{\theta}$:

$$\widehat{\theta} = T(R_1, R_2, \ldots, R_T) \sim ??? \quad \forall T \in \mathbb{N}$$

2. Dans la plupart des cas, la distribution des rendements $R_1, R_2, \ldots, R_T$ est **inconnue** ...

$$\widehat{\theta} = T(R_1, R_2, \ldots, R_T) \sim ??? \quad \forall T \in \mathbb{N}$$

Question : Comportement asymptotique

Question : quel est le comportement de l'estimateur $\widehat{\theta}_T$ lorsque la taille d'échantillon T tend vers l'infini ?

Définition (Théorie asymptotique) :
La **théorie asymptotique ou théorie des grands échantillons** consiste en l'étude de la distribution de l'estimateur lorsque la taille d'échantillon est suffisamment grande.

La théorie asymptotique est fondamentalement basée sur la notion de **convergence**.

Types de convergence

On distingue deux types de convergence :

1. **Convergence en probabilité** (ou en moyenne quadratique, ou presque sûre) : $\widehat{\theta}_T$ converge vers un nombre réel

Ces types de convergence sont utilisés pour dériver la propriété de **convergence** des estimateurs.

2. **Convergence en distribution** : $\sqrt{T}\left(\widehat{\theta}_T - \theta_0\right)$ converge vers une distribution donnée (par exemple, normale)

Cette convergence est utilisée pour dériver la **distribution asymptotique** des estimateurs et pour faire de l'**inférence** (tests) sur la vraie valeur des paramètres.

Définition (Convergence en probabilité)

Soit X_T une séquence de variables aléatoires indexée par la taille d'échantillon. X_T **converge en probabilité** vers une constante c, si, pour tout $\varepsilon > 0$,

$$\lim_{T \to \infty} \Pr(|X_T - c| > \varepsilon) = 0$$

On écrit :

$$X_T \xrightarrow{p} c \quad \text{ou} \quad \text{plim } X_T = c$$

Illustration de la convergence en probabilité

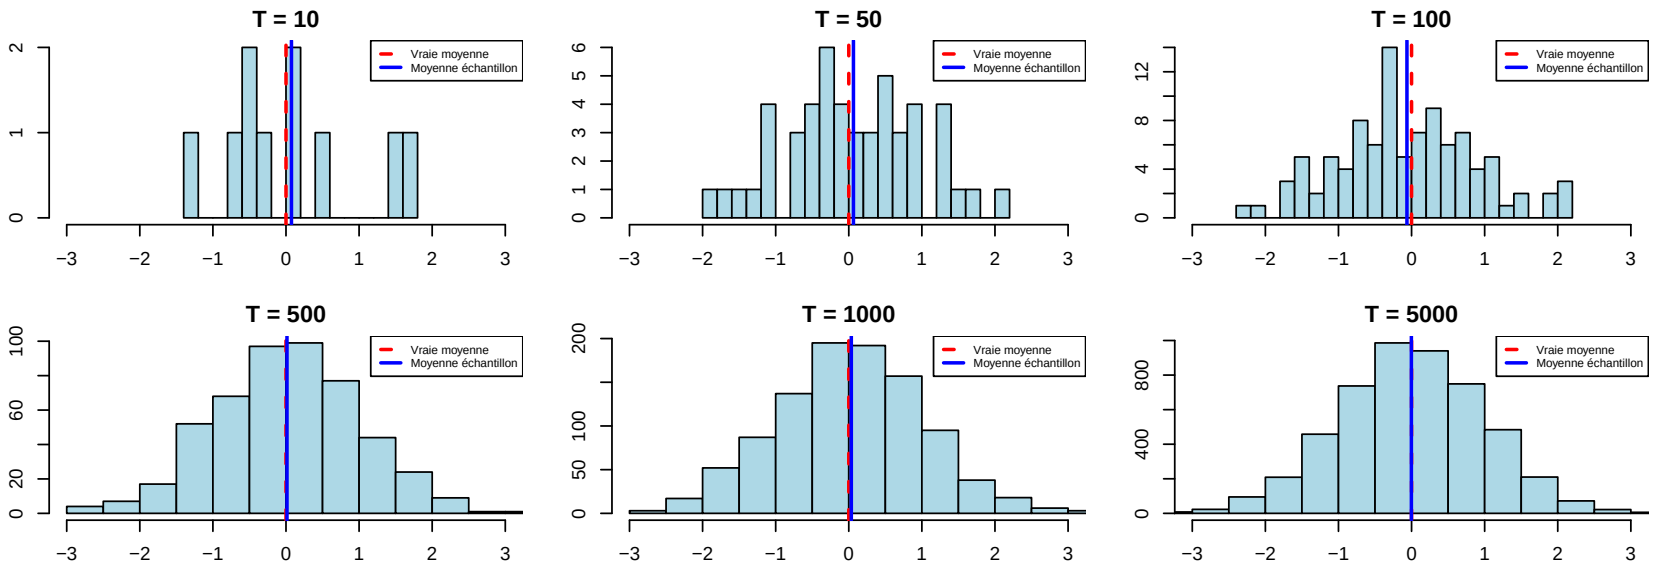

Théorème (convergence)

Si les rendements $R_1, R_2, ..., R_T$ sont i.i.d. avec des moments finis, $\mathrm{E}(R_t) = \mu$, $\mathrm{V}(R_t) = \sigma^2$, $S(R_t)$ et $\mathrm{K}(R_t)$, alors les quatre premiers moments d'échantillon sont **faiblement convergents**

$$\widehat{\mu}_T \xrightarrow{p} \mathrm{E}(R_t) = \mu$$

$$\widehat{\sigma}_T^2 \xrightarrow{p} \mathrm{V}(R_t) = \sigma^2$$

$$\widehat{S}_T \xrightarrow{p} S(R_t)$$

$$\widehat{K}_T \xrightarrow{p} \mathrm{K}(R_t)$$

Interprétation

- La distribution des moments d'échantillon est très concentrée autour de la vraie valeur (inconnue) des moments populationnels des rendements lorsque la taille d'échantillon T tend vers l'infini.
- La réalisation des moments d'échantillon (moyenne, variance, asymétrie, etc.) est alors "proche" de la valeur du moment populationnel lorsque la taille d'échantillon T tend vers l'infini.

Définition (Convergence en distribution)

Soit X_T une séquence de variables aléatoires indexée par la taille d'échantillon avec une fonction de répartition $F_T(.)$. X_T converge en distribution vers une variable aléatoire X avec fonction de répartition $F(.)$ si

$$\lim_{T \to \infty} F_T(x) = F(x) \quad \forall x$$

On écrit :

$$X_t \xrightarrow{d} X$$

Théorème (distributions asymptotiques pour moyenne et variance)

Si les rendements $R_1, R_2, ..., R_T$ sont i.i.d. avec une espérance finie $\mathrm{E}(R_t) = \mu$ et une variance finie $\mathrm{V}(R_t) = \sigma^2$, alors on peut dériver les **distributions asymptotiques** suivantes quand T tend vers l'infini :

$$\sqrt{T}(\widehat{\mu}_T - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$$

$$\sqrt{T}(\widehat{\sigma}_T^2 - \sigma^2) \xrightarrow{d} \mathcal{N}(0, 2\sigma^4)$$

Remarque : Interprétation des résultats asymptotiques

Les résultats asymptotiques

$$\sqrt{T}\left(\widehat{\mu}_T - \mu\right) \xrightarrow{d} \mathcal{N}\left(0, \sigma^2\right)$$

$$\sqrt{T}\left(\widehat{\sigma}_T^2 - \sigma^2\right) \xrightarrow{d} \mathcal{N}\left(0, 2\sigma^4\right)$$

peuvent être interprétés comme

$$\widehat{\mu}_T \overset{asy}{\approx} \mathcal{N}\left(\mu, \frac{\sigma^2}{T}\right) \quad \widehat{\sigma}_T^2 \overset{asy}{\approx} \mathcal{N}\left(\sigma^2, \frac{2\sigma^4}{T}\right)$$

où le symbole $\overset{asy}{\approx}$ signifie "distribué asymptotiquement comme".

Note : Ces résultats asymptotiques pour les moments d'échantillon peuvent être utilisés pour effectuer des tests statistiques sur les moments (populationnels).

Exemple (intervalle de confiance)

Considérons un échantillon de $T = 500$ rendements i.i.d. $R_1, ..., R_T$, et une réalisation (jeu de données) $\{r_1, ..., r_T\}$ avec

$$\widehat{\mu}_T = \overline{r}_T = -0.057 \quad \widehat{\sigma}_T^2 = 0.0009$$

Question : calculer un intervalle de confiance à 95% sur la vraie valeur de l'espérance de rendement $E(R_t)$.

Réponse

Nous savons que $\widehat{\mu}_T \overset{asy}{\approx} N(\mu, \sigma^2/T)$, donc nous avons

$$IC_{95} = \left[\mu \pm \frac{\sigma}{\sqrt{T}}\Phi^{-1}(0.975)\right]$$

Puisque μ et σ^2 sont inobservables, nous pouvons utiliser un estimateur convergent (approche plug-in) et nous obtenons

$$IC_{95} = \left[\widehat{\mu} \pm \frac{\widehat{\sigma}}{\sqrt{T}}\Phi^{-1}(0.975)\right] = \left[-0.057 \pm \sqrt{\frac{0.0009}{500}}\Phi^{-1}(0.975)\right] = [-0.0596; -0.0544]$$

Distribution asymptotique de l'asymétrie et de la kurtosis

Sous l'hypothèse de normalité, nous pouvons dériver la distribution asymptotique des coefficients d'asymétrie et de kurtosis.

Théorème (distributions asymptotiques pour asymétrie et kurtosis d'échantillon) : Si nous supposons que les rendements $R_1, R_2, ..., R_T$ sont $\mathcal{N}.i.d.(\mu, \sigma^2)$, alors nous avons

$$\sqrt{T}\left(\widehat{S}_T - 0\right) \xrightarrow{d} \mathcal{N}(0, 6)$$

$$\sqrt{T}\left(\widehat{K}_T - 3\right) \xrightarrow{d} \mathcal{N}(0, 24)$$

Note : Ces résultats asymptotiques pour les moments d'échantillon peuvent être utilisés pour effectuer des tests statistiques sur la distribution des rendements (test de Jarque-Bera par exemple).

Concepts clés (Section 4)

- ☒ Distribution des rendements
- ☒ Moments centraux et non centraux
- ☒ Moyenne, variance, asymétrie et kurtosis
- ☒ Distribution leptokurtique ou mésokurtique
- ☒ Distribution symétrique ou asymétrique
- ☒ Échantillon, estimateur, estimation et statistique (descriptive)
- ☒ Variables aléatoires indépendantes et identiquement distribuées (i.i.d.)
- ☒ Distribution d'échantillonnage d'un estimateur
- ☒ Distribution en échantillon fini vs distribution asymptotique
- ☒ Median Absolute Deviation (MAD)
- ☒ Inter Quartile Range (IQR)

Section 5 : Faits Stylisés

Objectifs

- Présenter les principaux faits stylisés des séries financières
- Définir la propriété de stationnarité des rendements d'actifs
- Montrer l'absence d'autocorrélations des rendements d'actifs
- Montrer les queues épaisses et l'asymétrie de la distribution des rendements
- Montrer le clustering de la volatilité
- Définir la gaussianité agrégative
- Introduire la dépendance à longue mémoire
- Définir l'effet de levier

Introduction aux faits stylisés

- Les propriétés statistiques des données financières ont révélé une richesse de **faits stylisés**.
- Ces faits stylisés sont communs à une large gamme de séries temporelles financières.

Cont, R. (2001), Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues, Quantitative Finance, 1, 223-236

L'exemple tout au long de la section porte sur l'indice journalier S&P500 entre 2021 et 2025, soit 1255 observations.

```
## [1] "GSPC"
```

```
## [1] 1259
```

Faits stylisés selon Fan et Yao (2015)

Fan et Yao (2015) identifient 8 faits stylisés principaux :

1. **Stationnarité**
2. **Absence d'autocorrélations**
3. **Queues épaisses**
4. **Asymétrie**
5. **Clustering de la volatilité**
6. **Gaussianité agrégative**
7. **Dépendance à longue mémoire**
8. **Effet de levier**

Fan, J. et Yao, Q. The Elements of Financial Econometrics, Science Press, Beijing, 2015

Fait stylisé 1 : Stationnarité

En général, les prix sont non stationnaires tandis que les rendements sont stationnaires.

Les prix d'un actif enregistrés au fil du temps sont souvent non stationnaires en raison, par exemple, de l'expansion régulière de l'économie, de l'augmentation de la productivité et des crises financières.

Cependant, leurs rendements fluctuent typiquement autour d'un niveau constant, suggérant une moyenne constante dans le temps.

La plupart des séquences de rendements peuvent être modélisées comme des processus stochastiques avec au moins les deux premiers moments invariants dans le temps : stationnarité faible.

Définition (stationnarité faible ou d'ordre deux)

Un processus de séries temporelles $(x_t, t \in \mathbb{Z})$ est **faiblement stationnaire** (stationnarité d'ordre deux) si et seulement si :

1. $\forall t \in \mathbb{Z}$, $\mathrm{E}(x_t^2) < \infty$
2. $\forall t \in \mathbb{Z}$, $\mathrm{E}(x_t) = \mu$ ne dépend pas de t
3. $\forall (t, h) \in \mathbb{Z}^2, \mathrm{Cov}(x_t, x_{t+h}) = \mathrm{E}((x_{t+h} - m)(x_t - m)) = \gamma_h$ ne dépend pas de t

Illustration graphique : Prix vs Rendements

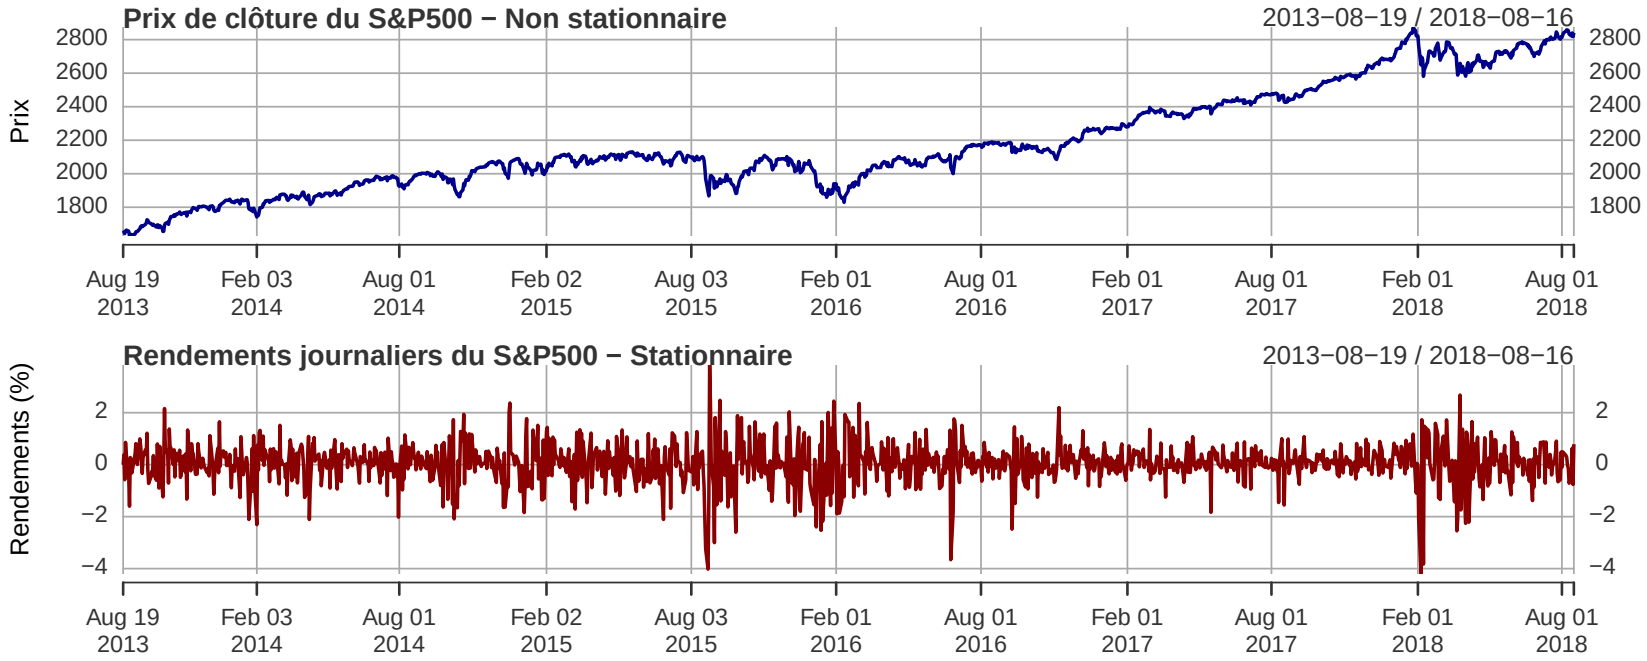

Fait stylisé 2 : Absence d'autocorrélations

Les autocorrélations des rendements d'actifs R_t sont souvent non significatives, sauf pour des échelles de temps intrajournalières très petites ($\simeq$ 20 minutes) pour lesquelles des effets de microstructure entrent en jeu.

Note : Le fait que les rendements ne montrent guère d'autocorrélation sérielle ne signifie pas qu'ils sont indépendants.

Définition (autocorrélation)

L'autocorrélation, notée $\rho(k)$, d'un processus faiblement stationnaire R_t est la corrélation entre les valeurs du processus à des temps différents, définie comme :

$$\rho_k = \mathrm{Corr}(R_t, R_{t-k}) = \frac{\mathrm{E}((R_t - \mu)(R_{t-k} - \mu))}{\mathrm{V}(R_t)} = \frac{\gamma_k}{\sigma^2}$$

avec $\mu = \mathrm{E}(R_t), \sigma^2 = \mathrm{V}(R_t), \forall t$ et γ_k l'autocovariance d'ordre k.

Définition (autocorrélation d'échantillon)

L'autocorrélation d'échantillon, notée $\widehat{\rho}(k)$, d'un processus faiblement stationnaire R_t, est un estimateur de $\rho(k)$ défini comme

$$\widehat{\rho}_k = \operatorname{corr}(R_t, R_{t-k}) = \frac{1}{(T-k)\sigma^2} \sum_{t=k+1}^{T} \left(R_t - \widehat{\mu}\right)\left(R_{t-k} - \widehat{\mu}\right)$$

où σ^2 et $\widehat{\mu}$ sont des estimateurs convergents de $\mu = \mathrm{E}(R_t)$ et $\sigma^2 = \mathrm{V}(R_t)$, $\forall t$.

Fonction d'autocorrélation (ACF)

La Fonction d'AutoCorrélation (ACF) représente l'autocorrélation d'échantillon pour différents retards de $k = 1$ à un ordre de retard maximum, disons $k = 15$.

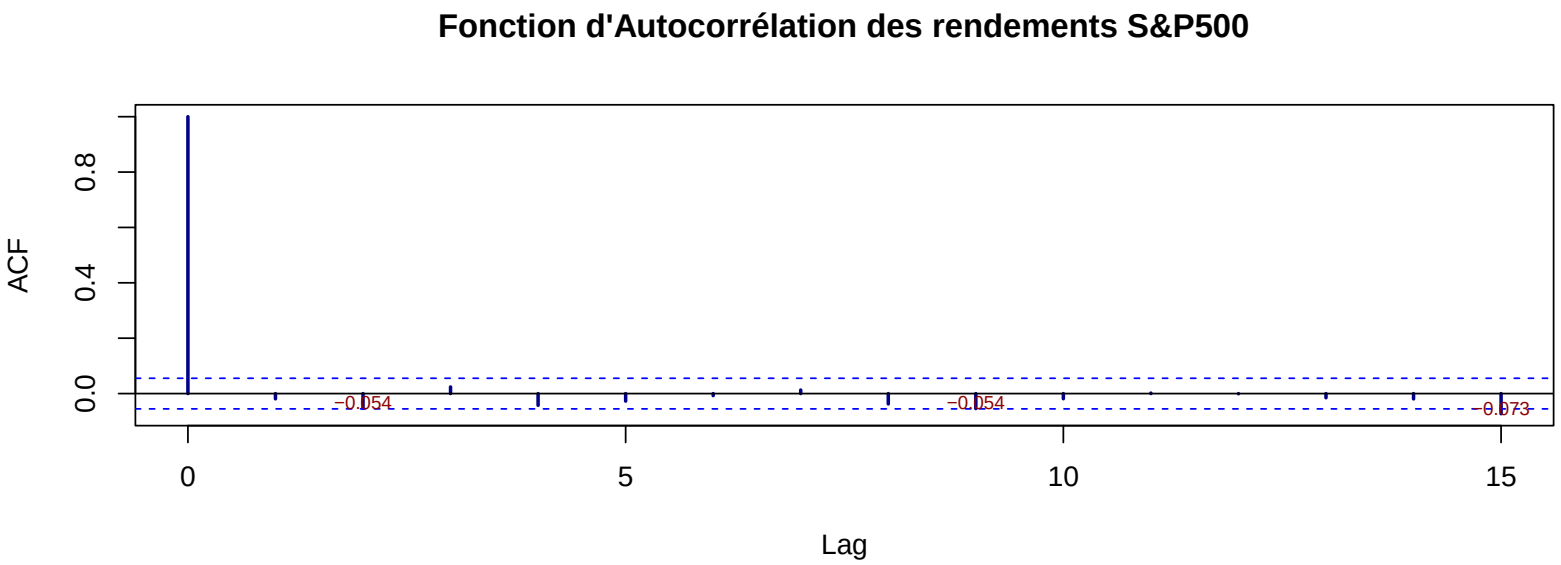

Test de nullité des autocorrélations

- Il est possible de tester la nullité des autocorrélations via un test Q (test de Box-Pierce ou test de Ljung-Box).
- Pour plus de détails sur les tests statistiques : cf. Chapitre 3.
- Pour un ordre de retard donné K, l'hypothèse nulle du test est

$$H_0 : \widehat{\rho_1} = \ldots = \widehat{\rho_K} = 0$$

- L'hypothèse alternative est

$$H_1 : \exists j \in \{1, \ldots, K\} \,/\, \widehat{\rho_j} \neq 0$$

Test de Box-Pierce

La statistique de test de Box-Pierce est définie comme

$$Q_{BP} = T \sum_{k=1}^{K} \widehat{\rho}_k^2 \xrightarrow[H_0]{d} \chi^2(K)$$

Règle de décision :

- Si la réalisation de la statistique de test Q_{BP} est plus grande que le quantile d'une distribution chi-deux avec K degrés de liberté à la probabilité $1-\alpha\%$ (disons, 95%), pour un niveau de risque $\alpha\%$ (disons, 5%) nous rejetons l'hypothèse nulle H_0.
- Si la p-valeur associée à la statistique de test Q_{BP} est plus petite que le niveau de risque $\alpha\%$ (disons, 5%), nous rejetons l'hypothèse nulle H_0.

Définition (test Q de Ljung-Box)

En général, les logiciels économétriques rapportent la statistique de test **Q de Ljung-Box**, définie comme

$$Q_K = T\,(T+2)\sum_{k=1}^{K}\frac{\widehat{\rho}_k^2}{T-k}\xrightarrow[H_0]{d}\chi^2(K)$$

Table 7: Statistiques Q de Ljung-Box pour les rendements du S&P500 (Août 2013 - Août 2018)

Lag	ACF	PACF	Q-Stat	P-Value
1	-0.019	-0.019	0.460	0.4976
2	-0.054	-0.054	4.076	0.1303
3	0.024	0.022	4.799	0.1871
4	-0.043	-0.045	7.086	0.1314
5	-0.027	-0.027	8.029	0.1547
6	-0.008	-0.014	8.100	0.2309
7	0.013	0.012	8.310	0.3060
8	-0.037	-0.039	10.088	0.2589
9	-0.054	-0.057	13.824	0.1287
10	-0.019	-0.028	14.270	0.1610
11	0.002	-0.003	14.274	0.2182
12	-0.001	-0.004	14.275	0.2835
13	-0.015	-0.022	14.568	0.3351
14	-0.019	-0.027	15.044	0.3751
15	-0.073	-0.079	21.828	0.1124

Fait stylisé 3 : Queues épaisses

La distribution de probabilité des rendements présente souvent des queues plus épaisses que celles d'une distribution normale.

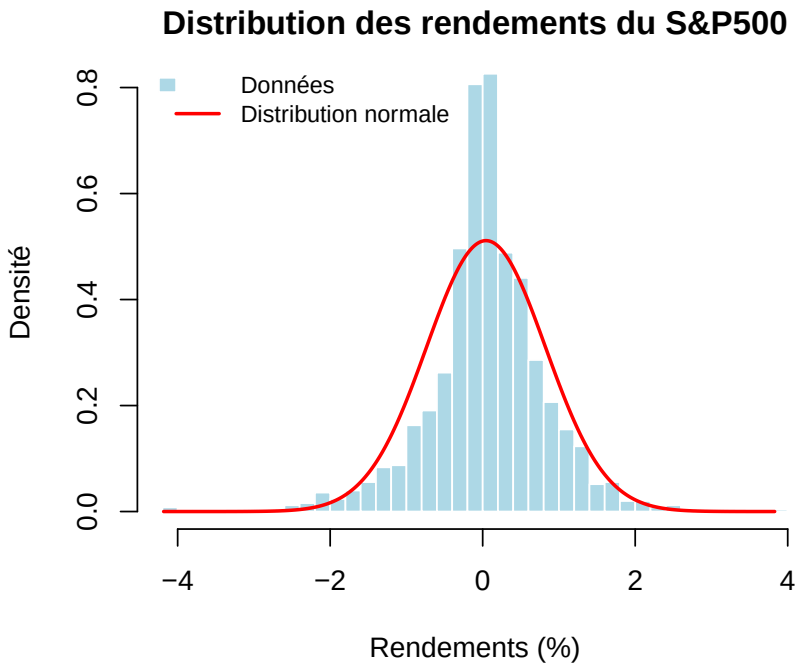

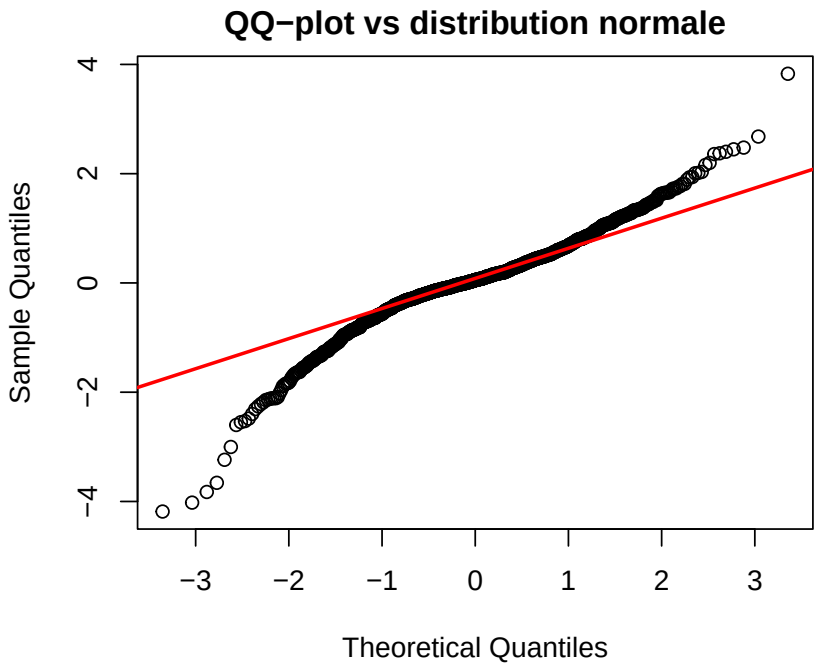

Statistiques descriptives S&P500

Table 8: Statistiques descriptives - Rendements journaliers SP500 (2013-2018)

Statistique	Valeur
Moyenne	0.043341
Écart-type	0.780467
Asymétrie	-0.5661
Kurtosis	6.4066
Minimum	-4.1843
Maximum	3.8291

Test de la kurtosis

- Considérons le test :

$$H_0 : \mathrm{K}(R_t) = 3 \quad H_1 : \mathrm{K}(R_t) > 3$$

- Une statistique de test peut être définie comme

$$\frac{\widehat{K}_T - 3}{\sqrt{24/T}} \xrightarrow[H_0]{d} N(0,1)$$

Règle de décision :

- Si la réalisation de la statistique de test est plus grande que le quantile d'une distribution normale standard à la probabilité $1 - \alpha\%$ (disons, 95%), pour un niveau de risque $\alpha\%$ (disons, 5%) nous rejetons l'hypothèse nulle H_0.
- Si la p-valeur associée à la statistique de test est plus petite que le niveau de risque $\alpha\%$ (disons, 5%), nous rejetons l'hypothèse nulle H_0.

Exemple (test sur la kurtosis)

Pour l'indice S&P500, le coefficient de kurtosis d'échantillon a une réalisation égale à 6.4066 pour une taille d'échantillon $T = 1259$.

Question : tester l'hypothèse nulle $H_0 : \mathrm{K}(R_t) = 3$ contre $H_1 : \mathrm{K}(R_t) > 3$ pour un niveau de risque $\alpha = 5\%$.

Réponse

La réalisation de la statistique de test est égale à :

$$\frac{\widehat{K}_T - 3}{\sqrt{24/T}} = \frac{6.4066 - 3}{\sqrt{24/1259}} = 24.6731$$

Pour un niveau de risque $\alpha = 5\%$, la valeur critique est égale à :

$$\text{valeur critique} = \Phi^{-1}(1-\alpha) = \Phi^{-1}(0.95) = 1.6449$$

où $\Phi(.)$ est la fonction de répartition d'une distribution normale standard.

Conclusion : Pour un niveau de risque $\alpha = 5\%$, nous rejetons l'hypothèse nulle $H_0 : \mathrm{K}(R_t) = 3$ en faveur de $H_1 : \mathrm{K}(R_t) > 3$, c'est-à-dire une distribution leptokurtique.

Fait stylisé 4 : Asymétrie

La distribution des rendements est asymétrique et souvent asymétrique négativement, reflétant le fait que les baisses des marchés financiers sont souvent beaucoup plus abruptes que les reprises. Les investisseurs ont tendance à réagir plus fortement aux mauvaises nouvelles qu'aux bonnes nouvelles.

Test de l'asymétrie

- Considérons le test :

$$H_0 : S(R_t) = 0 \quad H_1 : S(R_t) < 0$$

- Une statistique de test peut être définie comme

$$\frac{\widehat{S}_T}{\sqrt{6/T}} \xrightarrow[H_0]{d} N(0,1)$$

Règle de décision :

- Si la réalisation de la statistique de test est plus petite que le quantile d'une distribution normale standard à la probabilité $\alpha\%$ (disons, 5%), pour un niveau de risque $\alpha\%$ (disons, 5%) nous rejetons l'hypothèse nulle H_0.
- Si la p-valeur associée à la statistique de test est plus petite que le niveau de risque $\alpha\%$ (disons, 5%), nous rejetons l'hypothèse nulle H_0.

Exemple (test sur l'asymétrie)

Pour l'indice S&P500, le coefficient d'asymétrie d'échantillon est égal à -0.5661 pour une taille d'échantillon $T = 1259$.

Question : nous voulons tester l'hypothèse nulle $H_0 : S(R_t) = 0$ contre $H_1 : S(R_t) < 0$ pour un niveau de risque $\alpha = 5\%$.

Réponse

La réalisation de la statistique de test est égale à :

$$\frac{\widehat{S}_T}{\sqrt{6/T}} = \frac{-0.5661}{\sqrt{6/1259}} = -8.1996$$

Pour un niveau de risque $\alpha = 5\%$, la valeur critique est égale à :

$$\text{valeur critique} = \Phi^{-1}(\alpha) = \Phi^{-1}(0.05) = -1.6449$$

Conclusion : Pour un niveau de risque $\alpha = 5\%$, la statistique de test est plus petite que la valeur critique, donc nous rejetons l'hypothèse nulle $H_0 : S(R_t) = 0$ (distribution symétrique) en faveur de $H_1 : S(R_t) < 0$, c'est-à-dire une distribution asymétrique à gauche.

Fait stylisé 5 : Clustering de la volatilité

Le clustering de la volatilité signifie que les grands changements de prix (c'est-à-dire les rendements avec de grandes valeurs absolues ou de grands carrés) se produisent en grappes. En effet, les grands changements de prix ont tendance à être suivis par de grands changements de prix, et les périodes de tranquillité alternent avec des périodes de forte volatilité.

Note : le clustering de la volatilité est la conséquence de l'autocorrélation des rendements au carré (cf. Fait stylisé 7).

Illustration du clustering de la volatilité

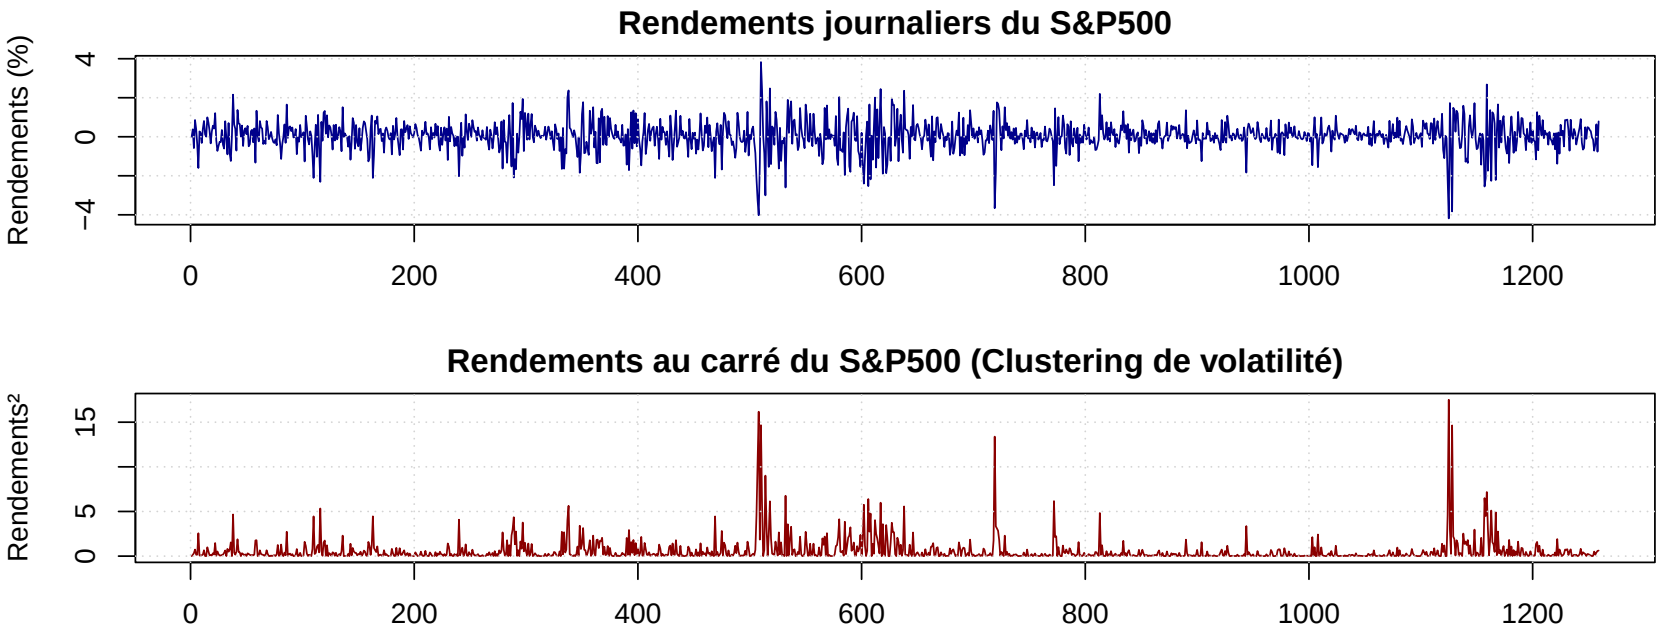

Fait stylisé 6 : Gaussianité agrégative

Un rendement sur k jours est simplement l'agrégation de k rendements journaliers. Lorsque l'horizon temporel k augmente, la loi des grands nombres entre en jeu et la distribution des rendements sur un horizon temporel long (tel qu'un mois) tend vers une distribution normale.

Définition (test de Jarque-Bera)

Le test de Jarque-Bera est :

$$H_0 : S(R_t) = 0 \text{ et } \mathrm{K}(R_t) = 3$$

$$H_1 : S(R_t) \neq 0 \text{ et/ou } \mathrm{K}(R_t) \neq 3$$

La statistique de test de Jarque-Bera est définie comme

$$JB = \frac{T}{6}\widehat{S}_T^2 + \frac{T}{24}\left(\widehat{K}_T - 3\right)^2 \xrightarrow[H_0]{d} \chi^2(2)$$

où $\widehat{S}_T$ et $\widehat{K}_T$ désignent respectivement les coefficients d'asymétrie et de kurtosis d'échantillon.

Test de Jarque-Bera

Interprétation :

- Le test de Jarque-Bera n'est pas un test de normalité. Cependant, si l'hypothèse nulle est rejetée, la distribution de R_t ne peut pas être normale.
- Si on ne parvient pas à rejeter l'hypothèse nulle, cela implique seulement que la distribution est symétrique et mésokurtique (la distribution normale n'est pas la seule dans ce cas).

Règle de décision :

- Si la statistique de test JB est plus grande que le quantile d'une distribution chi-deux avec 2 degrés de liberté à la probabilité $1 - \alpha\%$ (disons, 95%), pour un niveau de risque $\alpha\%$ (disons, 5%) nous rejetons l'hypothèse nulle H_0.
- Si la p-valeur associée à la statistique de test JB est plus petite que le niveau de risque $\alpha\%$ (disons, 5%), nous rejetons l'hypothèse nulle H_0.

Exemple (statistique de test de Jarque-Bera)

Pour l'indice S&P500, les coefficients d'asymétrie et de kurtosis d'échantillon sont égaux à -0.566051 et 6.406564, respectivement, pour une taille d'échantillon $T = 1259$.

Question : calculer la réalisation de la statistique de test de Jarque-Bera et conclure pour un niveau de signification de 5%.

Réponse

La réalisation de la statistique de test de Jarque-Bera est égale à :

$$JB = \frac{T}{6}\widehat{S}_T^2 + \frac{T}{24}(\widehat{K}_T - 3)^2 = \frac{1259}{6}(-0.566051)^2 + \frac{1259}{24}(6.406564 - 3)^2$$

$$= 676.00$$

Pour un niveau de risque $\alpha = 5\%$, la valeur critique est égale à :

$$\text{valeur critique} = F_2^{-1}(\alpha) = F_2^{-1}(0.95) = 5.9915$$

où $F(.)$ est la fonction de répartition d'une distribution chi-deux avec 2 degrés de liberté.

Conclusion : Pour un niveau de risque $\alpha = 5\%$, la statistique de test est plus grande que la valeur critique, donc nous rejetons l'hypothèse nulle (distribution symétrique et mésokurtique). La distribution des rendements journaliers ne peut pas être normale.

Fait stylisé 7 : Dépendance à longue mémoire

Les rendements absolus et au carré journaliers présentent souvent des autocorrélations significatives. Ces autocorrélations sont persistantes pour les rendements absolus, indiquant des propriétés potentielles de mémoire longue.

Note : Ces autocorrélations deviennent plus faibles et moins persistantes lorsque l'intervalle d'échantillonnage est augmenté d'un jour, à une semaine, à un mois.

Comparaison ACF : Rendements vs Rendements au carré

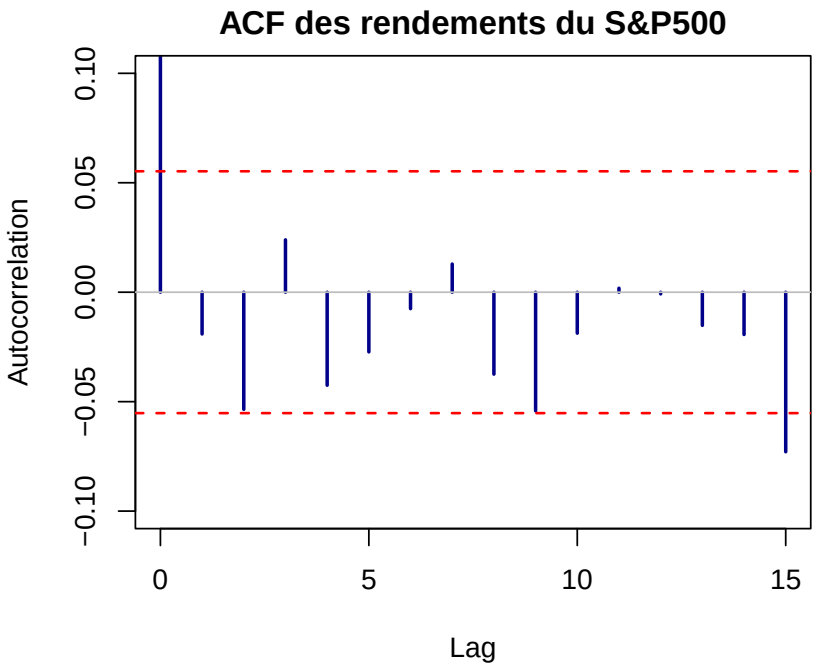

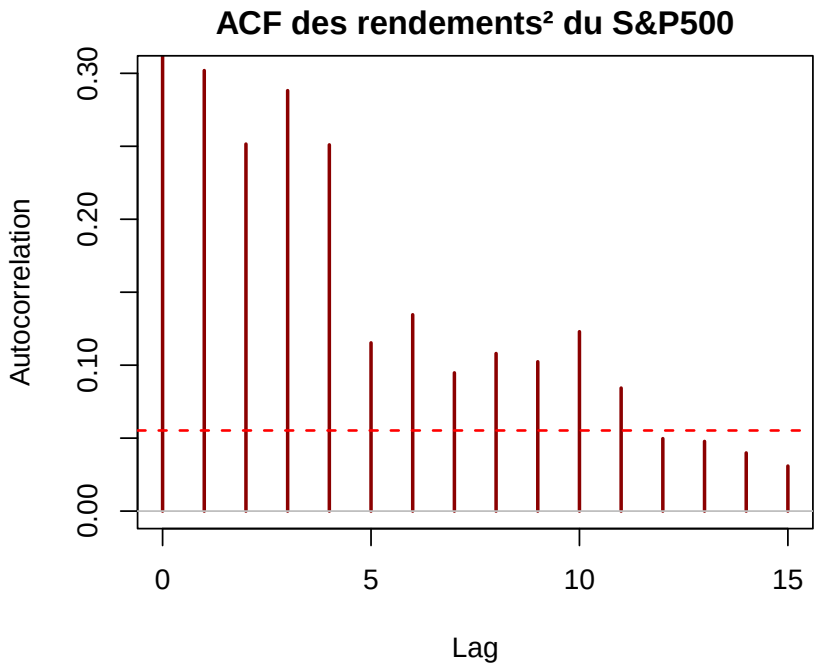

Remarques

- L'autocorrélation des rendements au carré est appelée **effet ARCH**.
- L'effet ARCH dépend de la fréquence d'échantillonnage.
- Il est plus important avec les rendements journaliers, et moins important avec les rendements de basse fréquence (mensuels, trimestriels, etc.).

Fait stylisé 8 : Effet de levier

Les rendements des actifs sont négativement corrélés avec les changements de leur volatilité : cette corrélation négative est appelée effet de levier.

- Lorsque les prix des actifs diminuent, les entreprises deviennent plus endettées (les ratios dette/fonds propres augmentent) et plus risquées, et donc leurs prix d'action deviennent plus volatils.
- D'autre part, lorsque les prix des actions deviennent plus volatils, les investisseurs exigent des rendements plus élevés et donc les prix des actions baissent.
- Les volatilités causées par la baisse des prix sont typiquement plus grandes que les appréciations dues aux volatilités diminuées.

Concepts clés (Section 5)

- ☒ Stationnarité
- ☒ Absence d'autocorrélation
- ☒ Effet ARCH
- ☒ Queues épaisses et distribution leptokurtique
- ☒ Distribution asymétrique
- ☒ Clustering de la volatilité
- ☒ Gaussianité agrégative
- ☒ Dépendance à longue mémoire
- ☒ Effet de levier

Conclusion du Chapitre 1

Synthèse

Ce premier chapitre a introduit les concepts fondamentaux de l'économétrie financière :

1. **Définition et objectifs** de l'économétrie financière
2. **Types de données** financières (prix, rendements, fréquences)
3. **Propriétés statistiques** des rendements (moments, distributions)
4. **Faits stylisés** des séries financières

Références complémentaires

- **Cont, R. (2001)** - *Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues*
- **Tsay, R. (2002)** - *Analysis of Financial Time Series*
- **Campbell, Lo, MacKinlay (1997)** - *The Econometrics of Financial Markets*
- **Alexander, C. (2008)** - *Market Risk Analysis*